Lab3 – Analizator wyników

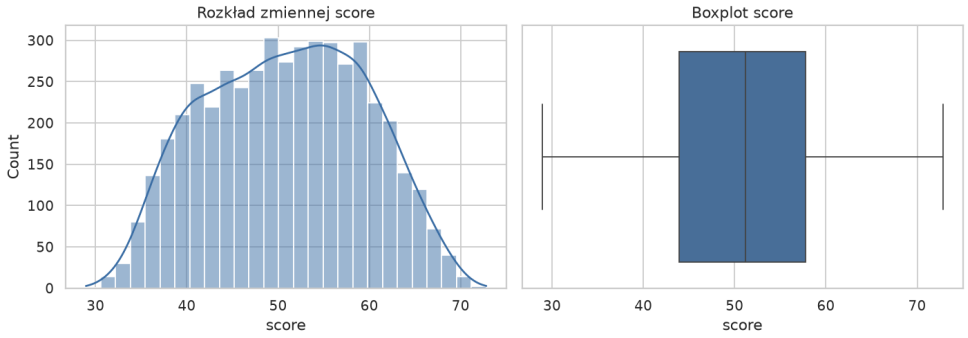
Predykcja zmiennej score · zbiór CollegeDistance (AER) · 2026-11-02

Pozycja	Wartość
Najlepszy model	Gradient Boosting (tuning)
Test: R^2 / MAE / MSE / RMSE	0.341 / 5.73 / 49.05 / 7.00
R^2 (5-fold CV)	0.342 ± 0.024
Train / test	3791 / 948

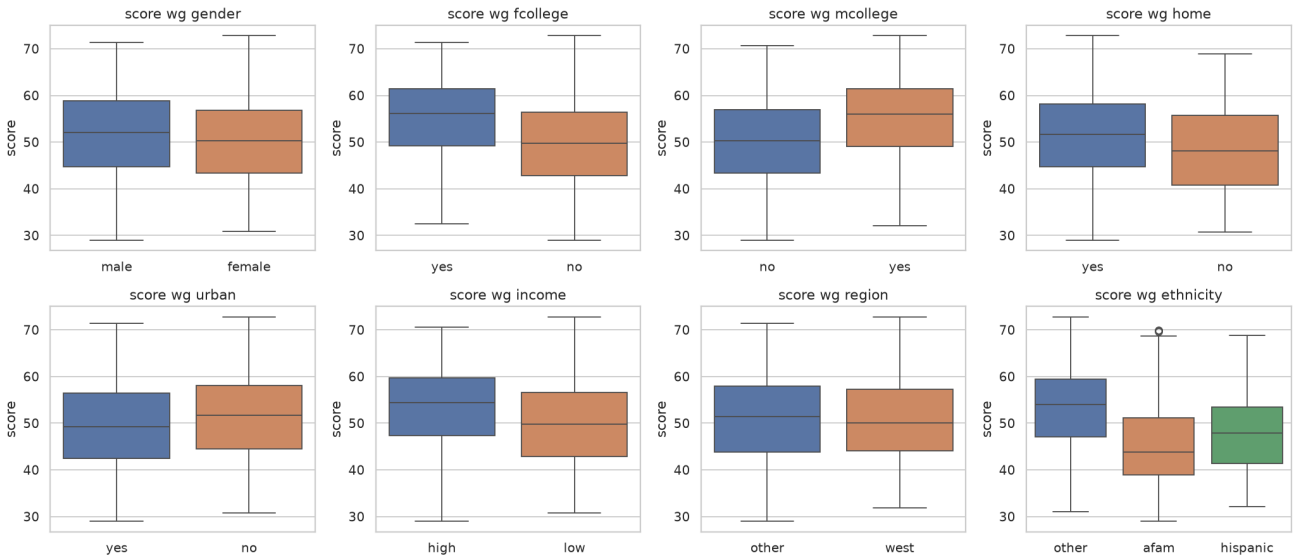
1. Eksploracja danych

4739 obserwacji, 13 cech: 5 liczbowych (unemp, wage, distance, tuition, education), 7 binarnych (gender, fcollege, mcollege, home, urban, income, region) i ethnicity (3 kategorie). Cel score to wynik testu kompetencji w ostatniej klasie szkoły średniej (średnia 50.9, odch. std. 8.7, rozkład zbliżony do normalnego).

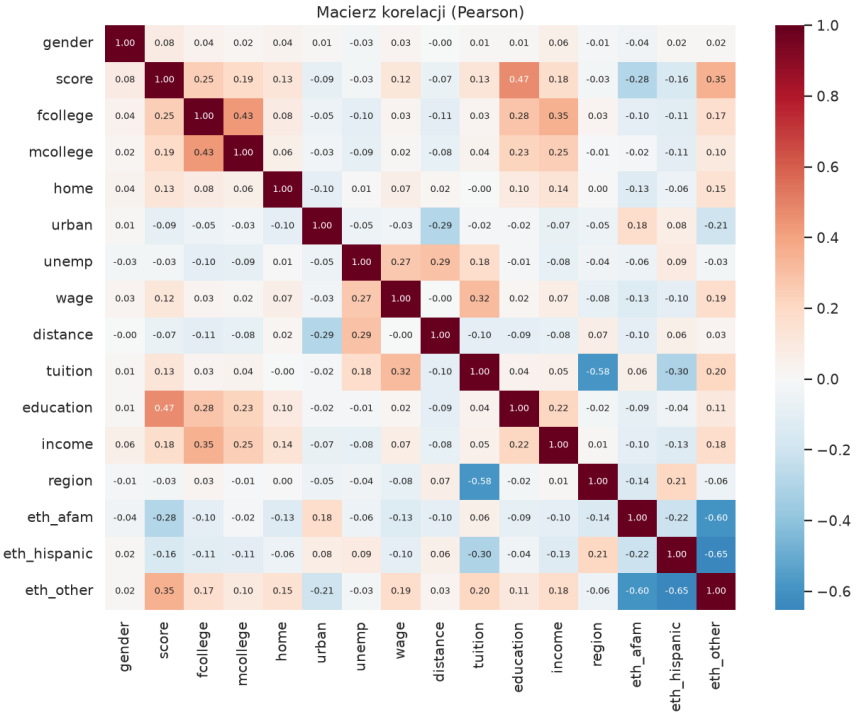
Braki: 0, duplikaty: 0. Proces i tak obsługuje braki (usunięcie wierszy bez score, imputacja medianą/modą w pipeline). Outliery wg 1,5·IQR (unemp 206, wage 272, distance 268) pozostawiono – to realne obserwacje.



Rys. 1. Rozkład score.



Rys. 2. score wg kategorii – największe różnice: etniczność, wykształcenie rodziców, dochód.



Rys. 3. Korelacje. Najsilniejsze ze score: education (+0.47), eth_other (+0.35), eth_afam (-0.28), fcollege (+0.25).

2. Inżynieria cech

• zmienne binarne → 0/1, ethnicity → one-hot (drop='first'),

• nowe cechy: parents_college (fcollege + mcollege), log_distance (prawoskośność), wage_unemp_ratio (rynek pracy), edu_beyond_hs (lata nauki po szkole średniej),

• standaryzacja zmiennych liczbowych (wymagana przez Ridge i MLP), imputacja w pipeline,

• podział 80/20 ze stratyfikacją po kwintylach score; transformacje dopasowywane tylko na train (brak wycieku danych).

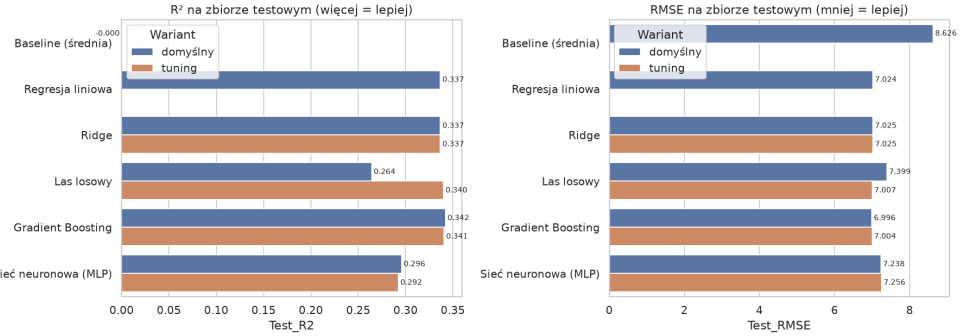
3. Modele

Baseline (średnia), regresja liniowa, Ridge (L2 – stabilna przy skorelowanych cechach), las losowy i Gradient Boosting (nieliniowości, interakcje) oraz sieć neuronowa MLP. Każdy oceniony 5-fold CV na train, potem na teście.

4. Ocena i optymalizacja

Tuning: RandomizedSearchCV (5-fold, kryterium MSE). Model finalny wybrano po wyniku CV, test służy tylko do końcowej oceny.

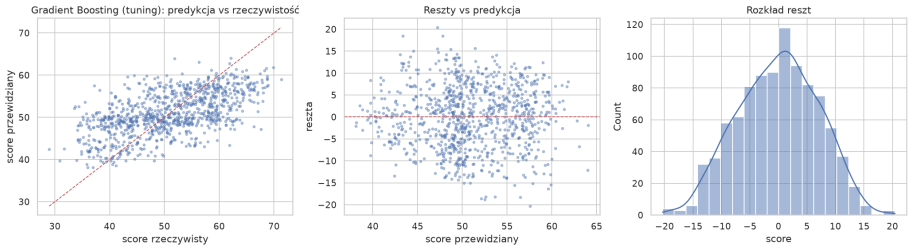
Model	Wariant	CV_R2	CV_RMSE	Test_R2	Test_MAE	Test_MSE	Test_RMSE
Baseline (średnia)	domyślny	-0.001	8.721	-0.000	7.263	74.402	8.626
Regresja liniowa	domyślny	0.333	7.121	0.337	5.738	49.343	7.024
Ridge	domyślny	0.333	7.121	0.337	5.738	49.344	7.024
Las losowy	domyślny	0.251	7.546	0.264	6.016	54.740	7.399
Gradient Boosting	domyślny	0.340	7.085	0.342	5.716	48.945	6.996
Sieć neuronowa (MLP)	domyślny	0.305	7.268	0.296	5.940	52.392	7.238
Ridge	tuning	0.333	7.121	0.337	5.739	49.344	7.025
Las losowy	tuning	0.337	7.100	0.340	5.729	49.093	7.007
Gradient Boosting	tuning	0.343	7.070	0.341	5.727	49.052	7.004
Sieć neuronowa (MLP)	tuning	0.310	7.240	0.292	5.901	52.646	7.256



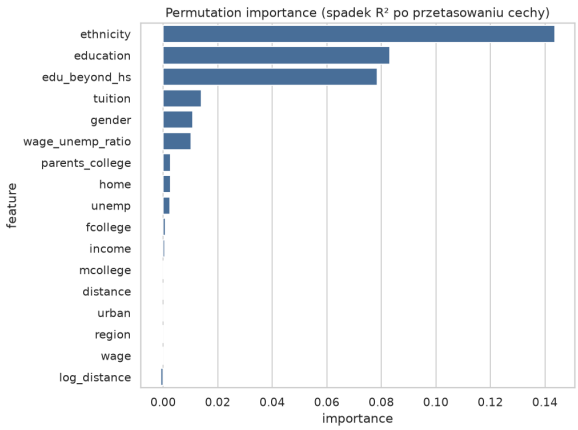
Rys. 4. Porównanie modeli na zbiorze testowym.

Gradient Boosting wyjaśnia ok. 34% wariancji (MAE 5.73 pkt). CV ≈ test, więc brak przeuczenia. Tuning najbardziej pomógł lasowi losowemu (R^2 0.264 → 0.340). Przewaga nad regresją liniową (R^2 0.337) jest niewielka – zależności są w dużej mierze addytywne.

Uwaga: education to lata nauki ukończone po teście. Bez niej model osiąga $R^2 = 0.184$. Umiarkowane R^2 wynika z braku w zbiorze kluczowych zmiennych (np. wcześniejszych ocen), a nie z wyboru modelu.



Rys. 5. Diagnostyka najlepszego modelu.



Rys. 6. Permutation importance – dominują: ethnicity, education, edu_beyond_hs.